

Università degli Studi di Padova
Dipartimento di Scienze Statistiche
Corso di Laurea Triennale in
Statistica per l'Economia e l'Impresa



RELAZIONE FINALE
**Realizzazione di un laboratorio di serie storiche con R:
l'approccio classico**

Relatore Prof. Francesco Lisi
Dipartimento di Scienze Statistiche

Laureando: Federico Perina
Matricola N° 2014183

Anno Accademico 2023/2024

ABSTRACT

L'obiettivo di questo laboratorio di serie storiche è quello di supportare lo studio delle serie storiche mediante l'approccio classico, utilizzando funzioni matematiche e medie mobili. A tal fine, è stata sviluppata un'applicazione interattiva in R tramite la libreria "Shiny", che consente agli utenti di interagire attraverso una varietà di widget e di distribuire facilmente le applicazioni sia localmente che su server remoti.

L'applicazione presenta un menù suddiviso per la stima di trend e stagionalità mediante funzioni matematiche, e per la stima delle serie storiche mediante medie mobili. Ogni pagina realizzata offre grafici e tabelle che si aggiornano automaticamente nel momento in cui vengono scelti o modificati gli input disponibili, come i parametri per la generazione delle serie o i modelli da utilizzare per la stima.

Questa applicazione è concepita quindi come uno strumento di supporto per facilitare la comprensione degli argomenti trattati nell'analisi delle serie storiche secondo l'approccio classico, rendendoli più accessibili rispetto ad uno studio esclusivamente teorico.

INDICE

Introduzione	Pag. 4
Capitolo Primo – Stima del trend mediante funzioni matematiche	
1.1 Criteri per la scelta del grado del polinomio	Pag. 6
1.2 Trend polinomiale con cambi strutturali	Pag. 8
1.3 Trend esponenziale	Pag. 10
Capitolo Secondo – Stima della componente stagionale mediante funzioni matematiche	
2.1 Stagionalità mediante variabili dummy	Pag. 13
Capitolo Terzo – Le medie mobili	
3.1 Effetto di Slutsky-Yule	Pag. 16
3.2 Conservazione del trend	Pag. 19
3.3 Eliminazione di un'onda periodica	Pag. 21
Conclusioni	Pag. 24

INTRODUZIONE

Le serie storiche rappresentano una componente fondamentale nell'analisi statistica ed economica, essendo strumenti essenziali per comprendere e prevedere fenomeni che si sviluppano nel tempo, e la loro analisi trova applicazione in una vasta gamma di settori, tra i quali l'economia, la finanza, ma anche la meteorologia, la demografia e molte altre discipline scientifiche.

Nel corso degli anni si sono sviluppati due diversi approcci all'analisi delle serie storiche, ovvero l'approccio classico e l'approccio moderno, i quali hanno differenti caratteristiche, metodologie ed obbiettivi. Questa tesi sarà focalizzata su quello classico, con il quale si assume che il processo generatore dei dati di una serie storica possa essere descritto da un modello stocastico del tipo: $Y_t = f(t) + u_t$, dove $f(t)$ rappresenta la legge di evoluzione temporale del fenomeno, mentre u_t è la componente casuale che viene assimilata ad errore accidentale.

Inoltre, negli ultimi anni, lo sviluppo di strumenti interattivi per la visualizzazione e l'analisi dei dati ha reso questi argomenti più accessibili e comprensibili, ed è per questo motivo che si è deciso di creare un'applicazione interattiva che permettesse di avere un supporto didattico più intuitivo, complementare a quello che può essere un libro di testo o la spiegazione di un docente. Questa tesi si propone quindi di sviluppare un'applicazione che esplori vari argomenti relativi alle serie storiche seguendo l'approccio classico, nel quale l'utente avrà la possibilità di visualizzare grafici interattivi e tabelle e applicare metodi classici di analisi dei dati.

Per la realizzazione in particolare è stato deciso di sfruttare "Shiny", ovvero una libreria di R che permette, attraverso un'ampia scelta di codici, di creare applicazioni interattive che permettano all'utente di interagire attraverso una varietà di widget come slider, caselle di controllo, menu a tendina e campi di testo. Questi input possono essere utilizzati per modificare i parametri dell'analisi e visualizzare i risultati aggiornati immediatamente in output che rispondono ai cambiamenti in tempo reale. Inoltre Shiny consente di distribuire facilmente le applicazioni sia localmente che su server remoti, ed è quindi stato scelto anche per questo. Ad, esempio, con la piattaforma Shiny Server è possibile pubblicare applicazioni e condividerle con un ampio pubblico.

Per quanto riguarda i contenuti teorici e le metodologie utilizzate nell'analisi delle serie storiche si è invece fatto riferimento al libro di testo *Serie storiche economiche* di Di Fonzo Tommaso e Lisi Francesco edito da Carocci editore (2005), e nello specifico ai primi tre capitoli.

In particolare, nel primo capitolo (più precisamente nelle sottosezioni 1.2, 1.4 e 1.5) si fa riferimento alla terminologia e alle notazioni scientifiche che sono state utilizzate nella creazione dell'applicazione, in modo da garantire un riferimento specifico e ben preciso e per evitare possibili errori di interpretazione dei contenuti.

Nel secondo capitolo si possono trovare invece tutte le nozioni che riguardano la stima delle componenti di una serie storica mediante funzioni matematiche, che saranno quelle che caratterizzeranno i primi due capitoli di questa tesi. Infatti il primo capitolo sarà incentrato sulla stima del trend mediante funzioni polinomiali o esponenziali, mentre il secondo capitolo tratterà la stima della componente stagionale mediante le cosiddette "variabili dummy". Le sottosezioni del libro di testo a cui fare riferimento per questi due argomenti sono rispettivamente 2.1 per il primo e 2.2 per il secondo.

Infine, nel terzo capitolo del libro sono racchiusi tutti i concetti che fanno riferimento al terzo capitolo di questa tesi, ossia proprietà delle medie mobili e loro utilizzo nella stima delle componenti di una serie storica. Verrà quindi proposto un metodo che si può dire alternativo rispetto a quello dei primi due capitoli nella stima delle componenti, il quale avrà determinati vantaggi e svantaggi. In questo caso le sottosezioni a cui si fa riferimento vanno dalla 3.1 alla 3.6.

L'obiettivo di questo lavoro è quindi quello di proporre uno strumento di supporto che, oltre ad aiutare gli utenti nell'apprendimento e l'applicazione delle tecniche di analisi delle serie storiche, renda anche più interattivo lo studio di argomenti che hanno necessità di essere visualizzati concretamente per essere compresi al meglio.

Capitolo Primo

STIMA DEL TREND MEDIANTE FUNZIONI MATEMATICHE

Nell'approccio classico si assume che il processo generatore dei dati di una serie storica possa essere descritto da un modello stocastico del tipo: $Y_t = f(t) + u_t$, dove $f(t)$ rappresenta la componente sistematica della serie, mentre u_t è la componente casuale che solitamente si distribuisce secondo un WN (white noise) di media 0 e varianza σ^2 costante.

Supponendo che $f(t)$ sia composta dal solo trend, in genere essa può essere rappresentata mediante una qualche funzione del tempo, che deve essere stimata. Questo primo capitolo ha quindi lo scopo di presentare i metodi di stima per trend lineari (o linearizzabili) nei parametri.

1.1 Criteri per la scelta del grado del polinomio

La prima sezione dell'applicazione riguarda un aspetto fondamentale nella stima del trend polinomiale di una serie storica, ovvero quello dei criteri per la scelta del grado del polinomio. Si può assumere infatti che la funzione deterministica $f(t)$ sia un polinomio di grado q , e che sommata alla componente di errore generi un modello del tipo: $y_t = \alpha_0 + \alpha_1 t + \dots + \alpha_q t^q + \varepsilon_t$. Questa funzione è lineare nei parametri e facilmente stimabile, tuttavia presenta il problema di scelta dell'ordine q del polinomio, il quale dipende dal comportamento di fondo della serie storica, e può non essere facilmente individuabile.

Per questo motivo è stata realizzata una pagina che permettesse di comprendere al meglio come questi criteri funzionano, partendo appunto dalla generazione di serie storiche composte da trend polinomiale e componente di errore nel quale, tramite degli *slider*, è possibile scegliere i valori dei parametri che andranno a generare trend costanti, lineari, parabolici o cubici a seconda dei valori scelti (per un trend parabolico basterà quindi lasciare $\alpha_3 = 0$). Inoltre è possibile modificare la varianza della componente di errore, la quale verrà calcolata come percentuale scelta rispetto a quella del trend stimato. Per comodità è stato poi aggiunto un bottone di reset che riporta tutti i valori dei parametri a quelli iniziali.

A questo punto, dopo aver generato la serie, è possibile visualizzare i tre criteri secondo i quali viene poi scelto l'ordine q del polinomio, ovvero il criterio delle differenze successive, il confronto tra $\bar{R}^2$ e la significatività delle stime dei parametri.

Per quanto riguarda il primo criterio è possibile selezionare, e quindi visualizzare sul grafico che inizialmente mostra la serie generata, tutte le differenze successive calcolate come $(I - B)^r y_t$ per $r = 1, \dots, 4$ (in quanto nel caso in cui la serie diventi approssimativamente costante per $r = 4$ saremmo in presenza di un polinomio di grado $q = 3$).

Per il confronto tra $\bar{R}^2$ è invece stato inserito un grafico dinamico che, al variare dei parametri scelti, mostra i valori dell' $\bar{R}^2$ per ogni modello stimato tramite il polinomio di grado q ed evidenzia tra tutti il valore massimo (per $q = 0$ si avrà quindi un modello del tipo: $y_t = \alpha_0 + \varepsilon_t$, fino ad arrivare a $q = 3$ con un modello del tipo: $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \alpha_3 t^3 + \varepsilon_t$). In aggiunta al grafico è stata poi inserita una tabella che riporta tutti i valori calcolati dell' $\bar{R}^2$ affiancati da quelli dell' R^2 , per mostrare che, mentre il valore dell' R^2 aumenta sempre nel momento in cui si aggiunge un parametro al modello stimato (e quindi aumenta il grado del polinomio), quello dell' $\bar{R}^2$ tiene conto anche del numero di parametri stimati, e quindi compensa l'aumento di precisione del modello con la complessità della stima.

Infine, per l'ultimo criterio è stata inserita un'ulteriore tabella dove vengono riportate le significatività delle stime dei parametri per gli stessi modelli per cui sono stati calcolati anche l' R^2 e l' $\bar{R}^2$, ed è quindi possibile osservare per ogni modello se si hanno dei parametri stimati che non sono statisticamente significativi, che quindi portano a non accettare quel modello come il migliore per descrivere la serie storica.

Naturalmente, la presenza di questi criteri per la scelta del grado del polinomio presuppone che, nel momento in cui viene effettuata la decisione, vengano tenuti in considerazione in modo congiunto in quanto sarebbe errato affidarsi ad uno solo dei criteri ritenendosi quindi soddisfatti dei singoli risultati di esso. Per esempio, può spesso capitare che con il criterio delle differenze successive si giunga alla conclusione che per stimare una serie storica basti un modello che presenta un trend lineare, quando nella realtà il modello più adatto contiene un trend parabolico o addirittura cubico. Anche per quanto riguarda gli altri due criteri non ci si può ritenere soddisfatti dagli esiti singoli senza considerarli tutti nel loro complesso, in quanto potrebbe accadere che il valore dell' $\bar{R}^2$ sia il più alto o che i parametri di un modello siano tutti significativi senza che quello sia effettivamente il modello che meglio rappresenta l'andamento della serie storica.




Fig. 1 Esempio di trend quadratico

In fig. 1 si ha un esempio di serie storica generata secondo un trend quadratico, e si può notare che il criterio delle differenze successive suggerirebbe di fermarsi ad un trend lineare in quanto la seconda differenza porta già ad una serie approssimativamente costante. Anche per quanto riguarda la significatività dei parametri non sembra errato scegliere un modello con trend lineare. Se si controlla l' $\bar{R}^2$ si scopre però che il modello con trend quadratico sembra spiegare decisamente meglio la serie originaria, ed essendo la differenza talmente ampia, sembra molto più ragionevole scegliere di stimare il trend con un polinomio di grado 2.

1.2 Trend polinomiale con cambi strutturali

In questa seconda sezione dell'applicazione viene affrontato un tema secondario per quanto riguarda la stima del trend di una serie storica, che può però rivelarsi importante in determinati casi, ovvero quello della stima di un trend che presenta uno (o più) cambi strutturali. Per facilitare la comprensione dell'argomento, infatti, si è deciso di mostrare il caso di un singolo cambio di struttura nella serie, anche se nella realtà non è esclusa la possibilità che si trovino più cambi nella stessa serie, ma ciò che viene mostrato è perfettamente applicabile ad un qualsiasi numero di cambi strutturali.

In questo caso si è quindi deciso di generare serie storiche del tipo: $y_t = (a_0 + a_1 t) * d_1 + (b_0 + b_1 t) * d_2 + \varepsilon_t$ con d_1 variabile dummy che vale 1 per $t = 0, \dots, t_0$ e 0 altrove e con d_2 variabile dummy che vale 1 per $t = t_0 + 1, \dots, n$ e 0 altrove, e tramite degli *slider* è possibile scegliere sia il punto t_0 nel quale avverrà il cambio strutturale, sia il valore di tutti i parametri

utilizzati poi per generare la serie (nel caso in cui non venisse scelto t_0 verrà quindi generata una serie con un solo trend).

Come nella sezione riguardante i criteri per la scelta del grado del polinomio, è inoltre possibile modificare la varianza della componente di errore ε_t , la quale verrà calcolata come percentuale scelta rispetto a quella del trend stimato, e per comodità è stato poi aggiunto un bottone di reset che riporta tutti i valori dei parametri a quelli iniziali.

Modificando i parametri disponibili vengono quindi generate serie storiche con una componente di trend che viene composta da due differenti trend lineari (o trend costanti nel caso in cui si decidesse di lasciare impostati α_0 e b_0 uguali a 0) e con componente di errore distribuita secondo un WN di media 0 e varianza σ^2 costante.

Una volta generata la serie vengono calcolate due diverse stime che possono riprodurre l'andamento della serie originaria. La prima stima avviene tramite un modello del tipo: $y_t = \alpha_0 + \alpha_1 t + \varepsilon_t$, che presenta quindi un trend lineare come se non ci fossero cambi strutturali, mentre la seconda si basa su un modello più complesso, del tipo: $y_t = (\alpha_0 + \alpha_1 t) * d_1 + (\beta_0 + \beta_1 t) * d_2 + \varepsilon_t$ con d_1 e d_2 variabili dummy (le stesse introdotte in precedenza).

Le due stime che vengono calcolate possono essere quindi rappresentate insieme alla serie generata in un grafico dinamico per mostrare se la differenza tra di esse sia significativa o meno, in quanto una differenza netta suggerirebbe di sfruttare la stima con il modello più complesso (che in qualsiasi caso rappresenterebbe meglio la serie generata) mentre un caso in cui le due stime sembrano restituire risultati simili porterebbe a scegliere quella con il modello più semplice dato che verrebbero risparmiate le stime di due parametri aggiuntivi (facilitando quindi l'interpretazione dei risultati).

Per supportare tale decisione è poi stato aggiunto anche un ulteriore grafico dinamico che rappresenta i residui dei due diversi modelli, oltre ad una tabella dove, per ognuna delle due stime, vengono riportate le significatività dei parametri stimati e $\bar{R}^2$, che come viene spiegato nella sezione 1.1 sono elementi fondamentali per la scelta del modello più adatto per la stima di questo tipo di serie storiche.

L'obiettivo di questa sezione è quindi quello di mostrare, sia graficamente che tramite i criteri di scelta, la possibilità di stimare il trend con modelli più complessi nel caso in cui si abbia un notevole miglioramento dal punto di vista della rappresentazione della serie storica ma, al contrario, mostrare anche casi in cui non si ha convenienza nell'applicazione di tali modelli e si può quindi optare per modelli più semplici.

Ad esempio, nel caso in cui il modello più complesso abbia qualche parametro non significativo, non sarebbe opportuno utilizzarlo anche se si ha un incremento in termini di $\bar{R}^2$. Allo stesso modo, nel caso in cui si abbia un valore dell' $\bar{R}^2$ simile per entrambi i modelli stimati, sarebbe più conveniente sfruttare il modello più semplice anche a discapito di qualche imprecisione nella stima.




Fig. 2 Esempio di trend lineare con cambio strutturale

In fig. 2 si può notare un esempio nel quale, pur essendo presente nella serie generata un leggero cambio strutturale a partire da t_0 , il modello con trend singolo presenta comunque un $\bar{R}^2$ molto elevato ed infatti sembra stimare in maniera adeguata la serie. Osservando anche il grafico dei residui (molto simile per i due modelli) sembra quindi non essere conveniente utilizzare il modello più complesso.

1.3 Trend esponenziale

Nella terza sezione dell'applicazione viene ancora affrontato il tema della stima del trend, ma per serie storiche che rappresentano fenomeni il cui andamento di lungo periodo viene caratterizzato da una rapida crescita apparentemente senza limiti, che è quindi difficilmente descrivibile da un trend di tipo polinomiale. Uno degli esempi più classici, che viene anche riportato nel libro di testo a cui si è fatto riferimento, è quello della serie annuale del numero di server Internet nel mondo, che negli ultimi anni ha avuto una crescita esponenziale.

Per questa e per molte altre serie è quindi più adatta una stima secondo una funzione esponenziale, del tipo: $f(t) = \alpha_0 e^{\alpha_1 t}$ con $\alpha_0 > 0$ e con un andamento che dipende dal valore del parametro α_1 . Partendo da questa funzione, si è quindi deciso di generare serie storiche

tramite il modello moltiplicativo, ossia: $y_t = a_0 e^{a_1 t} * \varepsilon_t$, con il quale vengono appunto rappresentate serie storiche con un andamento esponenziale e del quale, tramite appositi *slider*, è possibile modificare i parametri a_0 e a_1 oltre alla varianza del termine d'errore ε_t . Come nelle due precedenti sezioni, per comodità è stato poi aggiunto un bottone di reset che riporta tutti i valori dei parametri a quelli iniziali.

A questo punto l'obiettivo di questa specifica sezione è incentrato sui vantaggi riguardanti i due modelli che vengono utilizzati per stimare serie storiche di questo tipo, ovvero il modello moltiplicativo e quello additivo.

Il primo (quello utilizzato anche per generare le serie) si rivela vantaggioso in termini di stima dei parametri, in quanto è "linearizzabile" nei parametri. Infatti un modello del tipo: $y_t = \alpha_0 e^{\alpha_1 t} * \varepsilon_t$ può essere linearizzato mediante la trasformata logaritmica, risultando pari a: $\log y_t = \log \alpha_0 + \alpha_1 t + \log \varepsilon_t = \alpha_0^* + \alpha_1 t + \varepsilon_t^*$, e in questo caso bisogna assumere che sia ε_t^* ad essere distribuito secondo una normale con media nulla e varianza costante, quindi ε_t sarà di conseguenza distribuito secondo una log-normale. A causa di ciò si otterrà però una stima distorta del trend. Inoltre, la stima di α_0 secondo questo modello non sarà α_0^* , bensì sarà pari ad $\exp(\alpha_0^*) = \exp(\widehat{\log \alpha_0})$, quindi non più una stima ai minimi quadrati (in quanto la stima OLS non è invariante rispetto a trasformazioni).

Per ovviare a questi problemi è necessario quindi adottare il secondo tipo di modello, ovvero quello additivo, definito come: $y_t = a_0 e^{a_1 t} + \varepsilon_t$, che però non sarà né lineare né linearizzabile nei parametri. Per questo motivo il processo che porta alla stima dei parametri non avrà soluzione immediata e richiederà quindi una qualche procedura iterativa.

Per mostrare vantaggi e svantaggi dei due modelli si è quindi deciso di inserire un totale di 4 grafici, il primo dei quali mostra la serie storica che viene generata ogni volta che si decide di modificare un parametro o la varianza del termine d'errore. Il secondo e il terzo grafico rappresentano invece la serie stimata mediante modello moltiplicativo ed additivo, mostrando quanto esse si discostino dalla serie originaria e quindi quanto il modello sia efficace nella stima della serie generata. L'ultimo grafico riporta invece le serie dei residui dei due modelli, per rendere ancora più chiara l'efficacia delle rispettive stime.

In questo modo è possibile notare come in molti casi sia molto evidente il fatto che la stima mediante il modello moltiplicativo sia distorta, in quanto nel grafico che mostra il modello stimato l'ultimo valore solitamente si discosta notevolmente da quello della serie generata,

ed inoltre nel grafico che rappresenta i residui dei due modelli si ha un valore decisamente più elevato in termine assoluto rispetto a quello del modello additivo.




Fig. 3 Esempio di trend esponenziale con stima distorta per modello moltiplicativo

In fig. 3 si ha un chiaro esempio di ciò che è stato precedentemente illustrato, infatti osservando i grafici in cui vengono tracciate le serie stimate mediante i due modelli si può notare che il modello moltiplicativo genera una stima distorta della serie originaria, mentre quello additivo sembra stimare in modo più adatto la serie. Se si guarda il grafico dei residui tutto ciò è ancora più evidente, in quanto i residui del modello additivo (pur non essendo pari a 0) rimangono nettamente inferiori a quelli del modello moltiplicativo anche negli ultimi valori della serie.

Capitolo Secondo

STIMA DELLA COMPONENTE STAGIONALE MEDIANTE FUNZIONI MATEMATICHE

Come visto nel primo capitolo, nell'approccio classico per descrivere il processo generatore dei dati di una serie storica si utilizza un modello del tipo: $Y_t = f(t) + u_t$, con $f(t)$ componente sistematica ed u_t componente stocastica. Questa volta però $f(t)$ rappresenta la sola componente stagionale.

In questo secondo capitolo si assumerà quindi che il processo generatore della serie storica sia dato da: $Y_t = S_t + \varepsilon_t$, in cui $S_t = g(t)$ con $g(t)$ che rappresenta una funzione periodica ed ε_t rappresenta invece una componente residua. Si ricorda che si definiscono funzioni periodiche quelle funzioni il cui valore all'istante t si riproduce esattamente ad intervalli costanti, con periodo di lunghezza s (es. $s = 4$ per serie trimestrali, $s = 12$ per serie mensili, ...), ossia funzioni del tipo: $g(t) = g(t + s) = g(t + 2s) = g(t + 3s) = \dots$.

2.1 Stagionalità mediante variabili dummy

In questa sezione dell'applicazione viene mostrato uno dei metodi mediante il quale è possibile stimare una serie storica con componente stagionale, ovvero grazie all'utilizzo delle variabili dummy. Si suppone infatti che la funzione periodica $g(t)$ sia rappresentabile tramite una sommatoria del tipo: $\sum_{j=1}^s \gamma_j d_{jt}$ con $t = 1, 2, \dots, n$ e dove d_{jt} è la variabile cosiddetta dummy pari a: $d_{jt} = \begin{cases} 1 & \text{nel periodo } j - \text{esimo} \\ 0 & \text{altrimenti} \end{cases}$. I γ_j sono invece i relativi coefficienti, i quali rappresentano il livello che mediamente il fenomeno assume in corrispondenza di ciascuno degli s periodi infrannuali.

Nel momento in cui si vanno a stimare tali coefficienti (con il metodo dei minimi quadrati) con l'obiettivo poi di ricavare la serie destagionalizzata, ossia quella depurata dalla componente stagionale, le quantità risultanti sono dette "coefficienti grezzi di stagionalità". Per destagionalizzare la serie bisogna passare però dai cosiddetti "coefficienti ideali di stagionalità", che vengono ricavati come scarti dalla media rispetto a quelli grezzi (nel caso

in cui la media dei coefficienti grezzi fosse pari a 0 sarebbe indifferente utilizzarne un tipo rispetto all'altro).

Per la generazione delle serie storiche di questa sezione viene quindi utilizzato un modello del tipo: $Y_t = S_t + \varepsilon_t$ dove è possibile scegliere il periodo s secondo il quale si "ripete" la funzione $g(t)$ (che determinerà poi il numero di parametri che verranno stimati). Come in tutte le precedenti sezioni inoltre, ε_t si distribuisce secondo una normale di media 0 e varianza che viene calcolata in percentuale scelta tramite apposito *slider* rispetto alla stagionalità stimata.

Dopo aver generato la serie è possibile visualizzare due differenti grafici dinamici, il primo dei quali rappresenta proprio la serie stimata alla quale è inoltre possibile sovrapporre quella destagionalizzata, mostrando in questo modo quanto incidono la componente stagionale e quella d'errore.

Il secondo invece mostra contemporaneamente coefficienti grezzi ed ideali in modo che, per ogni serie che viene generata, sia possibile notare la differenza tra i due (data ovviamente da un valore costante che è quello della media dei coefficienti grezzi) e quindi si possa avere un'idea della differenza che si avrebbe nel calcolare la serie destagionalizzata nei due casi. Intuitivamente quindi, più le due serie dei coefficienti si trovano distanti tra loro (quindi più la media è lontana da 0) e più i coefficienti ideali sono necessari per calcolare la serie destagionalizzata in modo corretto. Questo secondo grafico può poi essere sostituito da quello dei residui per poter verificare se la stima è adatta o se sono ancora presenti comportamenti periodici.

Sotto ai due grafici è stata poi inserita una tabella che riporta i valori di tutti i coefficienti grezzi che vengono stimati e dei corrispettivi coefficienti ideali, ed inoltre è presente anche il valore della media dei coefficienti grezzi che indica quanto differiscono da quelli ideali, oltre a quello della media dei coefficienti ideali, che a meno di errori di calcolo dovrebbe essere sempre pari a 0.




Fig. 4 Esempio di serie storica con periodo stagionale pari a 3 (quadrimestrale)

In fig. 3 viene rappresentato un esempio di ciò che si è illustrato, in quanto si nota subito la differenza tra coefficienti grezzi ed ideali (sia graficamente sia dal valore calcolato della media dei coefficienti grezzi, significativamente diversa da 0), e di conseguenza si può capire che destagionalizzando la serie storica tramite i coefficienti grezzi porterebbe ad un risultato totalmente differente.

Capitolo Terzo

LE MEDIE MOBILI

Nei primi due capitoli è stato trattato il tema della stima del trend e della stagionalità di una serie storica mediante funzioni matematiche, ossia descrivendo la componente di fondo come una qualche funzione del tempo. Questo metodo porta indubbiamente dei vantaggi, ma trova un grande limite nel momento in cui l'andamento del fenomeno si manifesta in modo irregolare. In questo caso infatti è necessario ricorrere a polinomi di grado troppo elevato, i cui risultati non sono di facile interpretazione (per questo motivo nella sezione 1.1 ci si è limitati a polinomi fino al grado 3).

Un modo alternativo di lavorare è allora quello di ricercare la componente di fondo senza dover necessariamente fissare una legge di variazione, il che è reso possibile da uno strumento molto flessibile come la “media mobile”, che è data da una trasformazione lineare delle osservazioni. Considerando una serie storica y_t con $t = 1, \dots, n$ per cui valga un modello additivo del tipo: $y_t = T_t + S_t + \varepsilon_t$, si va quindi a cercare una funzione g che abbia determinate caratteristiche e che, ad esempio, conservi il trend ed annulli le altre componenti. Questa funzione g è appunto la media mobile che, applicata alla serie storica, genererà una serie: $y_t^* = \sum_{i=-m_1}^{m_2} \vartheta_i y_{t+i}$, con $m_1, m_2 \in \mathbb{N}$ e $\vartheta_{-m_1}, \dots, \vartheta_{m_2} \in \mathbb{R}$ e dove il numero di termini $(m_1 + m_2 + 1)$ implicati nella trasformazione sarà l'*ordine* della media mobile mentre i ϑ_i saranno i *pesi* della media mobile.

Questo ultimo capitolo sarà dunque suddiviso in tre sezioni che riguarderanno i tre aspetti principali per cui vengono utilizzate le procedure fondate su medie mobili, ossia la stima del trend, la destagionalizzazione e la riduzione della componente erratica.

3.1 Effetto di Slutsky-Yule

La prima sezione dell'ultimo capitolo è incentrata sulla riduzione della componente erratica e sull'effetto che comporta l'applicazione di una media mobile sulla componente di disturbo ε_t , argomento che poi ritornerà anche nelle successive sezioni.

Se si considera una generica media mobile centrata (ossia con $m_1 = m_2 = m$) e la si applica ad ε_t si ottiene una serie del tipo: $\varepsilon_t^* = \sum_{i=-m}^m \vartheta_i \varepsilon_{t+i}$ con $t = 1, \dots, n$, che avrà caratteristiche ben precise, ossia avrà media nulla, in quanto: $E[\varepsilon_t^*] = \sum_{i=-m}^m \vartheta_i E[\varepsilon_{t+i}] = 0$, e varianza costante pari a $\sigma^{*2} = Var[\varepsilon_t^*] = \sigma^2 \sum_{i=-m}^m \vartheta_i^2$. Si può notare quindi che la variabilità della componente d'errore viene ridotta dalla trasformazione se $\sum_{i=-m}^m \vartheta_i^2 < 1$, e in questi casi si afferma che la media mobile svolge un'azione *spianante*, ovvero riduce le irregolarità di tipo casuale presenti in una serie storica. La quantità calcolata viene detta "rapporto di riduzione della varianza residua", in quanto deriva dal rapporto: $\frac{\sigma^{*2}}{\sigma^2}$, e misura appunto la capacità della media mobile di ridurre la perturbazione.

Questa trasformazione porta però a componenti tra loro correlate in quanto, essendo la media mobile una somma pesata dei valori della serie storica, per valori vicini della serie si avrà una covarianza pari a: $Cov[\varepsilon_t^*, \varepsilon_{t+h}^*] = \sigma^2 \sum_{i=h-m}^m \vartheta_i \vartheta_{i-h}$ se $h \leq 2m$. L'esistenza di queste correlazioni non nulle non rispetta quindi una delle ipotesi del classico errore *white noise* (che si ricorda essere a componenti incorrelate) ed introduce un effetto spurio che viene detto "effetto di Slutsky-Yule", il quale fa sì che la serie ε_t^* presenti oscillazioni più o meno regolari che possono apparire analoghe a quelle originate da una componente stagionale e possono rappresentare un elemento di disturbo in fase di stima delle altre componenti.

Si è quindi deciso di creare una pagina nella quale vengono generate serie storiche casuali di 100 osservazioni da un WN distribuito secondo una normale di media 0 e varianza scelta tramite uno *slider*, le quali verranno poi rappresentate in un grafico dinamico. Successivamente, è possibile applicare una media mobile scegliendone l'ordine e i pesi, i quali saranno inizialmente calcolati come semplice media aritmetica rispetto all'ordine della media mobile, ma sarà comunque possibile determinarli in modo manuale. Inoltre, nel caso venisse scelto un ordine m dispari, tramite apposito bottone si potrà applicare la centratura di due medie mobili semplici di ordine $m - 1$ (ad esempio, per una media mobile di ordine 5 i pesi saranno pari a: $\frac{1}{8}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{8}$). Una volta scelta la media mobile desiderata ed aggiornato il grafico, la serie stimata verrà visualizzata nel medesimo grafico di quella generata in modo che vi sia un impatto visivo della riduzione di variabilità (o meno) della serie.

Sono stati poi inseriti altri due grafici che rappresentano le funzioni di autocorrelazione rispettivamente della serie generata e di quella stimata mediante media mobile, potendo così notare che, mentre le correlazioni della serie generata rispecchiano quelle dell'errore

WN a componenti incorrelate (si ha solo una correlazione significativa in corrispondenza del lag 0), quelle della serie stimata sono significative anche per valori del lag successivi allo 0, dimostrando così che vi è appunto il cosiddetto “effetto di Slutsky-Yule”. Sotto ai grafici è stato infine inserito il valore del rapporto di riduzione della varianza residua.

In questo modo si può notare l'importanza della scelta riguardante la media mobile più adatta soprattutto dal punto di vista della riduzione della variabilità, in quanto una media mobile che non riduce la perturbazione della serie originaria non porta nessun vantaggio per quanto riguarda la stima della serie. Dall'altro lato si deve però fare attenzione (per quanto possibile) a non utilizzare trasformazioni che poi possono confondere rispetto alla componente stagionale, ad esempio facendo sì che il periodo medio delle oscillazioni spurie sia vicino al periodo della componente stagionale.



Fig. 5 Esempio di media mobile con rapporto di riduzione della varianza residua maggiore di 1

In fig. 5 si ha un chiaro esempio del motivo per il quale stimare una serie storica con medie mobili che non riducono la variabilità dell'errore non sia opportuna, in quanto si amplifica solamente l'effetto della componente di errore rendendo impossibile una qualsiasi interpretazione ed analisi riguardo la serie.



Fig. 6 Esempio di media mobile con apparente componente stagionale

Al contrario, in fig. 6 si ha un esempio di media mobile che riduce la variabilità della serie, ma che come si può notare dal grafico sembra generare una sorta di componente periodica che si ripete nel tempo, nonostante la serie non presenti alcun tipo di componente stagionale.

3.2 Conservazione del trend

In questa seconda sezione del capitolo viene affrontato un altro dei temi fondamentali riguardanti l'utilizzo di procedure fondate su medie mobili, ovvero quello della conservazione del trend e della sua stima mediante appunto medie mobili. Considerando una serie storica y_t con $t = 1, \dots, n$, essa viene detta invariante rispetto alla media mobile M se $My_t = y_t \forall t$ e in questi casi si dice che la media mobile M conserva y_t . Particolare importanza assume quindi il comportamento della media mobile rispetto a componenti deterministiche di tipo polinomiale, solitamente utilizzate per rappresentare il trend di una serie storica.

Partendo dal caso più semplice, ovvero quello del trend costante, si ha che una media mobile con pesi che sommano ad 1 ($\sum_{i=-m}^m \vartheta_i = 1$) conserva appunto la costante, mentre per polinomi di grado maggiore si può dimostrare che le condizioni affinché la media mobile conservi il polinomio sono: $\sum_{i=-m}^m \vartheta_i = 1$ e $\sum_{i=-m}^m i^r \vartheta_i = 0$ per $r = 1, \dots, p$. Si noti infine che una media mobile M , esprimibile come composizione di due medie mobili M_1 e M_2 che conservano entrambe polinomi di grado p , conserva anch'essa tali polinomi, e ciò si rivela molto importante nel momento in cui si vanno a considerare particolari medie mobili come ad esempio quelle di Spencer, le quali sono in grado di annullare componenti stagionali di periodo 4 e 5, conservando trend polinomiali fino al grado 3. Spesso però, al posto di utilizzare medie mobili complesse sia da un punto di vista di calcolo che, specialmente, da quello interpretativo, vengono utilizzate medie mobili più semplici ed intuibili. Infatti per la stima dei valori del trend si fa spesso affidamento a medie mobili centrate, come ad esempio: $y_t^{**} = \frac{1}{8}(y_{t-2} + 2y_{t-1} + 2y_t + 2y_{t+1} + y_{t+2})$ la quale si rivela una buona media mobile nel caso di dati trimestrali per stimare il trend, depurare la serie dalla stagionalità e ridurre la componente di errore. Altre medie mobili molto intuitive sono le medie mobili semplici come ad esempio: $y_t^{**} = \frac{1}{3}(y_{t-1} + y_t + y_{t+1})$. Da notare il fatto che quest'ultima, pur non essendo una media mobile che conserva polinomi di grado 2 (l'ultima condizione non viene soddisfatta), che quindi non può riprodurre esattamente un trend quadratico, può comunque fornire una stima ragionevolmente buona del trend in quanto riduce l'impatto

delle variazioni irregolari, rendendo il trend sottostante più evidente ed inoltre, se non varia rapidamente, può ancora approssimare bene su brevi intervalli.

Nel momento in cui si va a stimare il trend di una serie storica mediante media mobile bisogna quindi tenere in considerazione il tipo di trend che si va a stimare (costante, lineare, ...) ed un'eventuale componente di stagionalità (anche se per semplicità in questa sezione si è deciso di non inserirla), oltre a tutto quello che è stato spiegato in precedenza riguardo la riduzione della varianza residua.

Per questo motivo è stata realizzata una pagina che permette di generare serie storiche del tipo: $y_t = T_t + \varepsilon_t$ con T_t componente di trend ed ε_t componente di disturbo, con la possibilità di scegliere il tipo di trend (costante, lineare o quadratico) e la varianza di ε_t (che si distribuisce secondo una normale di media 0 e varianza calcolata in percentuale scelta rispetto a quella del trend). Una volta generata la serie, la quale verrà visualizzata in un grafico dinamico, è possibile applicare una qualsiasi media mobile scegliendone l'ordine e i pesi (analogamente a quanto è stato detto nella sezione precedente), ed aggiornando il grafico verrà calcolata la corrispondente stima insieme ai residui, i quali saranno rappresentati in un grafico a parte. Inoltre, è stata aggiunta una tabella nel quale, per ogni media mobile, vengono riportati i valori per le condizioni di conservazione del polinomio fino al grado 2. È così possibile capire quanto la media mobile scelta sia adatta o meno a stimare la serie storica generata, e quanto essa sia quindi in grado di riprodurre l'andamento della serie.



Fig. 7 Esempio di trend quadratico stimato mediante media mobile centrata

In fig. 7 si può notare che, come detto in precedenza, una media mobile centrata come quella nell'esempio permette di stimare in maniera soddisfacente la serie storica generata con trend quadratico, nonostante non vengano rispettate tutte le condizioni per la

conservazione del polinomio. Lo si può vedere sia dal grafico in cui viene rappresentata dalla serie, in quanto la media mobile riduce la variabilità e mette in risalto la componente di trend, sia da quello dei residui i quali non sembrano presentare alcun comportamento atipico.



Fig. 8 Esempio di trend quadratico stimato con media mobile casuale

In fig. 8 si ha invece la medesima serie storica con trend quadratico, alla quale è stata però applicata una media mobile con pesi differenti (se pur con lo stesso ordine). É evidente che, mentre nell'esempio precedente la stima seguiva lo stesso andamento della serie storica generata, in questo la media mobile non è adatta e lo si nota chiaramente lungo tutta la serie. Osservando il grafico dei residui si ha un'ulteriore conferma di ciò che è stato appena affermato.

3.3 Eliminazione di un'onda periodica

In conclusione, l'ultima sezione del capitolo tratta l'eliminazione di un'onda periodica e lo studio della stagionalità di una serie storica, attraverso la stima della componente stagionale e la successiva destagionalizzazione. Partendo da serie storiche del tipo: $y_t = S_t + \varepsilon_t$ (o $y_t = S_t * \varepsilon_t$), si cerca quindi inizialmente di mettere in evidenza la componente stagionale S_t , determinando degli *scarti* o *coefficienti di stagionalità*, a seconda che il modello ipotizzato sia, rispettivamente, additivo o moltiplicativo, che esprimano per ogni periodo il peso di questa componente. Successivamente, depurando i valori osservati della serie storica dalla stagionalità, sarà così possibile confrontare direttamente gli ultimi dati disponibili (o l'ultimo) con quelli immediatamente precedenti, ottenendo informazioni sull'evoluzione più recente

del fenomeno, ed inoltre la serie destagionalizzata farà emergere l'andamento tendenziale dei fenomeni.

Inizialmente, vengono quindi stimati i valori del trend con medie mobili pari a y_t^{**} (solitamente centrate, come visto nella sezione 3.2), utilizzate poi per calcolare i cosiddetti *rapporti* o *indici specifici* di stagionalità, calcolati come: $IS_t = y_t - y_t^{**}$ o $IS_t = \frac{y_t}{y_t^{**}}$ in base al tipo di modello, e caratterizzati dalla presenza della componente accidentale. A partire da questi, vengono poi calcolati i *coefficienti grezzi* di stagionalità (analoghi a quelli della sezione 2.1) pari a: $\hat{S}_j^* = \frac{1}{N} \sum_{T=1}^N IS_{T,j}$ con $j = 1, \dots, p$ (es. $p = 12$ nel caso di dati mensili), i quali non sono però ancora adatti a destagionalizzare la serie. L'ultimo passaggio riguarda infatti il calcolo dei *coefficienti ideali* di stagionalità, caratterizzati dal fatto che il loro effetto si annulli all'interno dell'anno, e determinati come: $\hat{S}_j = \hat{S}_j^* - \frac{1}{p} \sum_{j=1}^p \hat{S}_j^*$ oppure $\hat{S}_j = \frac{\hat{S}_j^*}{\sqrt[p]{\prod_{j=1}^p \hat{S}_j^*}}$ sempre a seconda del modello ipotizzato. A questo punto è quindi possibile destagionalizzare la serie, calcolata come: $y_{T,j}^d = y_{T,j} - \hat{S}_j$ o $y_{T,j}^d = \frac{y_{T,j}}{\hat{S}_j}$, ossia sottraendo o dividendo i coefficienti alla serie storica.

A dimostrazione di ciò, si è quindi deciso di realizzare una pagina nella quale si possono generare serie storiche con componente stagionale di periodo scelto (quindi ad esempio serie con periodo 4 riprodurranno dati trimestrali) e componente d'errore a valori distribuiti secondo una normale di media 0 e varianza calcolata in percentuale scelta rispetto a quella della stagionalità. Una volta generata la serie, la quale verrà visualizzata in un grafico dinamico, è possibile selezionare il tipo di modello secondo il quale si vuole destagionalizzare e la media mobile che verrà utilizzata per calcolare le stime, scegliendone ordine e pesi (con le stesse modalità delle altre sezioni). Nel momento in cui si va ad aggiornare il grafico, vengono quindi calcolati tutti i coefficienti citati in precedenza, ovvero indici specifici, coefficienti grezzi ed ideali, i quali avranno ognuno un grafico dedicato. La serie destagionalizzata verrà invece aggiunta al grafico in cui è presente la serie originaria, in modo che si possa notare quanto la procedura è stata efficace o meno.

In questo modo si può vedere che, mentre gli indici specifici variano all'interno della serie e dipendono quindi dalla componente accidentale, i coefficienti grezzi ed ideali si ripetono costantemente per ogni periodo, e differiscono unicamente per un valore costante, ossia quello della media dei coefficienti grezzi.



Fig. 9 Esempio di serie storica trimestrale stimata con media mobile centrata di ordine 5

In fig. 9 si ha un esempio di ciò che si è illustrato, infatti dopo aver generato una serie storica di periodo 4, ossia con dati trimestrali, per stimare si è deciso di utilizzare la centratura di due medie mobili semplici di ordine pari al periodo della serie storica, che come detto in precedenza è una pratica molto utilizzata nel caso in cui si voglia eliminare un'onda periodica. Inoltre è possibile notare come i coefficienti specifici presentino un andamento irregolare, mentre quelli grezzi ed ideali siano costanti e differiscano soltanto per il valore della media (indicata dal segmento nero).

CONCLUSIONI

In questa tesi è stata esplorata l'analisi delle serie storiche attraverso l'approccio classico, sviluppando un'applicazione interattiva in R tramite la libreria "Shiny" con l'obiettivo principale di creare uno strumento didattico e pratico che potesse facilitare la comprensione e l'applicazione delle tecniche di analisi. Si è quindi cercato di sfruttare tutte le potenzialità di questa libreria implementando grafici dinamici e tabelle che, avendo la caratteristica di aggiornarsi in tempo reale, hanno permesso la realizzazione di un'applicazione efficace dal punto di vista didattico, con vantaggi specialmente dal punto di vista pratico rispetto alle classiche analisi svolte in R. Si sono potute quindi realizzare varie pagine con l'intento di mostrare nel modo più chiaro e diretto possibile i vari argomenti inclusi nell'approccio classico, ovvero quello della stima del trend e della stagionalità sia mediante funzioni matematiche che medie mobili, cercando di mostrarne al meglio caratteristiche, vantaggi e svantaggi.

Lungi dal voler esaurire l'argomento, questo elaborato si propone di essere un punto di partenza di un progetto sicuramente più ampio, sia dal punto di vista dei contenuti – con la possibilità di estendere le funzionalità per introdurre le tecniche di analisi che riguardano l'approccio moderno (o anche di aggiungerne altre per quanto riguarda quello classico) – sia dal punto di vista grafico, date le innumerevoli possibilità che librerie come "Shiny" concedono.